

# Análisis Matemático para Inteligencia Artificial

Verónica Pastor (vpastor@fi.uba.ar),  
Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

8/7/2022

El mundo del Data Science y las competencias de Machine Learning cobraron mucha relevancia con la [competencia de Netflix](#), que prometía **1M USD** a quien pudiera obtener una performance de un 10% por sobre su algoritmo de base para el problema de recomendación de películas.

En este contexto surgió una nueva variante de modelo en base a factorización de matrices.

¿Lo interesante? Con las dos clases de AM ya nos alcanza para entenderlo!

## ¿Por qué funciona la inversa? (1/2)

*Asimétrico*

Demostremos que:

$$|A| \neq 0 \rightarrow x \neq 0 \quad x^T A x > 0$$

Si  $A \in \mathbb{R}^{n \times n}$  es una matriz definida positiva, entonces es invertible:

Dem.: (por método del absurdo)

Supongamos que el determinante de  $A$  es cero, y llegaremos a una solución absurda.

Si  $\det(A) = 0$  y queremos resolver un sistema  $Ax = 0$  significa que además de la solución trivial hay infinitas soluciones, es decir  $\text{rango}(A) < n$ , entonces

$$\exists \tilde{x} \neq 0 : A\tilde{x} = 0 \Rightarrow \tilde{x}^T A \tilde{x} = \tilde{x}^T 0 = 0$$

y entonces no se cumple que  $\tilde{x}^T A \tilde{x} > 0$ .

$$u \left( \underbrace{\sum_{j=1}^k r_j r_j^T + \lambda I_k}_{A \text{ (k x k)}} \right) = \underbrace{\sum_{j=1}^k r_j r_j^T}_{\text{vector}}$$

## ¿Por qué funciona la inversa? (2/2)

Demostremos que:

$A = x \cdot x^T + \lambda I_k$  es definida positiva, es decir,  $y^T A y > 0$ ,  $\forall y \in \mathbb{R}^k - \{0\}$

Dem.: Sea  $y \in \mathbb{R}^k - \{0\}$

$$y^T (x \cdot x^T + \lambda I_k) y = \underbrace{(y^T x x^T y)}_{\text{p.i.}} + \underbrace{y^T \lambda I_k y}_{\text{p.i.}} =$$

(recordemos que el p.i. es  $\langle u, v \rangle = u^T v$ ), prop. asociativa,

$$= \underbrace{\langle y, x \rangle \langle x, y \rangle}_{\text{p.i.}} + \underbrace{\lambda \langle y, y \rangle}_{\text{p.i.}} = \underbrace{\langle x, y \rangle^2}_{\text{p.i.}} + \underbrace{\lambda \|y\|^2}_{\text{p.i.}} > 0.$$

$\therefore x \cdot x^T + \lambda I_k$  es definida positiva.

$\lambda > 0$   
pero  
de la  
regular:  
razón

# Proyección Ortogonal

## Proyección

Sea  $\mathbb{V}$  un EV y  $S \subset \mathbb{V}$  un SEV. Una transformación lineal  $\Pi : \mathbb{V} \rightarrow S$  es una proyección si  $\Pi^2 = \Pi \circ \Pi = \Pi$

Esto significa que la matriz de transformación asociada a la proyección cumple con la propiedad de idempotencia:  $[\Pi]^2 = [\Pi]$ .


## Proyección Ortogonal

Dado  $\mathbb{V}$  un EV con p.i. y  $S \subset \mathbb{V}$  un SEV, el objetivo es dado  $v \in \mathbb{V}$  hallar  $\tilde{v} \in S$  que sea “lo más parecido posible” a  $v$ .

$$\tilde{v} \in S : \tilde{v} = \arg \min_{s \in S} \|v - s\|$$

Además vale que  $\langle v - \tilde{v}, s \rangle = 0, \forall s \in S$

Obs: La ortogonalidad de la proyección tiene que ver con el p.i. que se use.



# Teorema de proyección

Sea  $\mathbb{V}$  un EV de dimensión finita con p.i.  $\langle \cdot, \cdot \rangle$ ,  $S$  un SEV. Dado  $v \in \mathbb{V}$  existe un único  $\tilde{v} \in S$  tal que

$$\|v - \tilde{v}\| \leq \|v - u\|, \quad \forall u \in S$$

¿Cómo hallar la proyección?

Sea  $\mathbb{V}$  un EV de dimensión  $n$  con p.i.  $\langle \cdot, \cdot \rangle$ , y  $S \subset \mathbb{V}$  un SEV,  $\dim(S) = m \geq 1$ , y sea  $B = \{s_1, \dots, s_m\}$  una BON de  $S$ . Buscamos encontrar la proyección de  $\tilde{v} \in S$  de  $v \in \mathbb{V}$  ( $\tilde{v} = \Pi_S(v)$ ).

Como  $\tilde{v} \in S$ ,  $\tilde{v} = \sum_{i=1}^m \alpha_i s_i \Rightarrow$  busco los coeficientes que minimizan  $\|v - \sum_{i=1}^m \alpha_i s_i\|$ . El problema puede escribirse como:

$$\Pi_S(v) = \sum_{i=1}^m \alpha_i s_i = B\alpha, \quad B = [s_1, \dots, s_m], \quad \alpha = [\alpha_1, \dots, \alpha_m]^T$$

## ¿Cómo hallar la proyección?

Como por definición  $\langle v - \Pi_S(v), s \rangle = 0, \forall s \in S$ , debo resolver el siguiente sistema de ecuaciones:

$B \rightarrow \Pi_S(v) = B\alpha$   
 $\langle v, r \rangle = v^T r$


$$\begin{cases} \langle v - \Pi_S(v), s_1 \rangle = 0 \\ \vdots \\ \langle v - \Pi_S(v), s_m \rangle = 0 \end{cases} \Rightarrow \begin{cases} s_1^T (v - B\alpha) = 0 \\ \vdots \\ s_m^T (v - B\alpha) = 0 \end{cases} \Rightarrow \begin{pmatrix} -s_1^T \\ \vdots \\ -s_m^T \end{pmatrix} (v - B\alpha) = 0$$

$$B^T(v - B\alpha) = 0 \Leftrightarrow B^T v = B^T B \alpha \Leftrightarrow \alpha = (B^T B)^{-1} B^T v$$

$$P_{\Pi_S} = B(B^T B)^{-1} B^T$$

Observación: Si  $B$  es una BON entonces  $P_{\Pi_S} = BB^T$ .

# Aplicación: Cuadrados Mínimos



Supongamos que tenemos un sistema sobredeterminado de la forma:

$$Ab = y, \quad A \in \mathbb{R}^{n \times m}, \quad b \in \mathbb{R}^m, \quad y \in \mathbb{R}^n, \quad m > n.$$

$b$  es la solución de cuadrados mínimos

Como  $m > n$ , puede que no exista  $b$  que satisfaga todas las  $n$  ecuaciones, entonces busco la solución que más se acerque (busco  $\text{Proy}_{\text{Col}(A)}y$ )

$$b = (A^T A)^{-1} A^T y \Rightarrow P = A(A^T A)^{-1} A^T$$



Ya vimos que el ajuste por cuadrados mínimos funciona en la teoría, ahora veámoslo funcionar en la práctica!