


# Un poco de series temporales



# Hablando de Series Temporales

## Mini Agenda

- Series de tiempo:
  - Definición
  - Componentes
  - Descomposición
- Algunos modelos básicos:
  - Media constante
  - Transformación logarítmica
  - Single Exponential Smoothing
  - Random walk
  - Tendencia lineal
  - Tendencia cuadrática

# Un poco de Series Temporales

## ¿ Qué son las series temporales ?

Una serie de tiempo es un conjunto de observaciones tomadas en *intervalos regulares*, ordenados por el momento en que se produjeron.

Time series analysis (*análisis de series de tiempo*) comprende métodos para *proyectar la evolución*, obtener *estadísticas y otras características* de una variable a lo largo del tiempo.

Time series forecasting (*Pronóstico de series de tiempo*) es el uso de los modelos para predecir futuros valores.

# Un poco de Series Temporales



Existen muchos ejemplos de datos que se pueden expresar como series de tiempo:

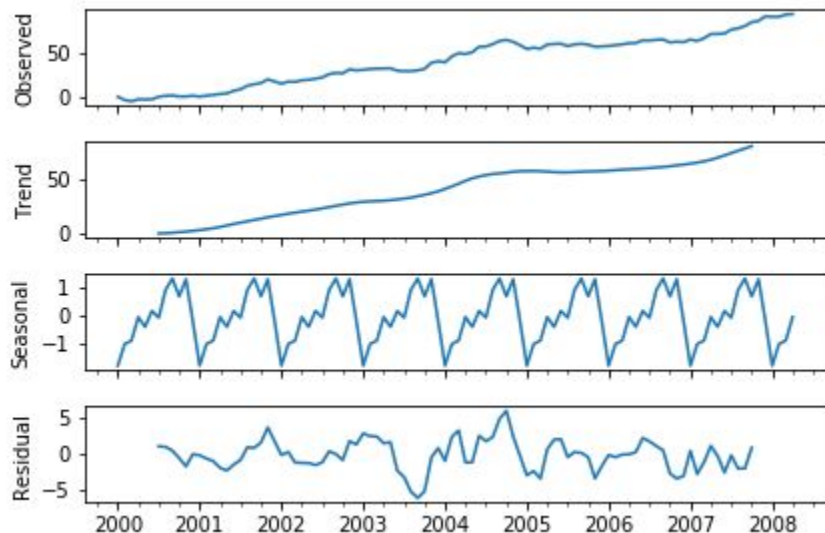
- Variables macroeconómicas (PBI, inflación, etc).
- Movimientos comerciales.
- Datos de producción.
- Consumo energético.
- Variables sociales (mortalidad infantil, pobreza...).

# Componentes de las series temporales

- Tendencia (Trend): es el componente permanente, el efecto persistente en el tiempo.
- Estacionalidad (Seasonality): es un patrón estacional que se repite con regularidad.
- Componente aleatoria (Residual): son shocks que no presentan un efecto duradero. Se los define también como ruido o movimientos random.
- Ciclos (Cycle): otro tipo de dinámica no capturada por la tendencia o estacionalidad.

# Descomposición de una serie de tiempo

El módulo statsmodels.api, con su método `tsa.seasonal_decompose` genera gráficos con: la serie de tiempo, la tendencia, la estacionalidad y el componente aleatorio.



Podemos pensar en descomponer una serie temporal en sus componentes. Básicamente, existen dos formas:

## Descomposición aditiva:

$$Y_t = S + C + e + T$$

## Descomposición multiplicativa:

$$Y_t = S * C * e * T$$

donde T es la tendencia, S es la estacionalidad, C es el ciclo y e es el error aleatorio

# Descomposición de una serie de tiempo

## Descomposición aditiva:

$$Y_t = S + C + e + T$$

La descomposición aditiva es útil cuando la variación estacional se *mantiene relativamente constante* (lineal). Digamos que la altura de sus picos es constante.

## Descomposición multiplicativa:

$$Y_t = S * C * e * T$$

La descomposición multiplicativa es útil cuando la *tendencia crece* y la *amplitud de la variación estacional aumenta* (exponencial). O cuando la tendencia y la amplitud decrece.

# Descomposición de una serie de tiempo

Estudiamos modelos aplicados a los componentes de las series para generar predicciones.

Para cada modelo:

- Lo *definimos*.
- Lo *ajustamos* a los datos de train.
- Lo *evaluamos* usando RMSE (podemos usar también MAPE o WAPE) sobre los datos de test.
- Lo *comparamos* con otros modelos.

Recordemos que el **error cuadrático medio raíz (RMSE)** compara los valores predichos con los valores observados.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



# Alerta


Cuando trabajamos con series temporales, OJO!!!

Dividimos el dataset en train y test igual que siempre, pero al ser una serie temporal, tenemos que poner *shuffle=False* (que no mezcle las observaciones), creando una continuidad entre los sets de entrenamiento y de testeo.

# Media constante

La media constante es el modelo más básico e ingenuo de todos.

Consiste simplemente en tomar *la media del dataset de train* y usarlo para predecir.



# Transformación logarítmica

En algunos casos, la varianza de la serie aumenta con el paso del tiempo.

Hacer una transformación logarítmica de la serie puede ayudar a estabilizar la varianza. Para esto haremos lo siguiente:

- Generamos el modelo sobre el logaritmo de las ventas(variable  $y$ ), tanto en train como en test.
- Generamos el modelo de regresión lineal usando el logaritmo de las ventas. Teniendo en cuenta train y test.
- Volvemos a transformar las predicciones a un valor de ventas, con una función exponencial.
- Este último valor será la predicción final, el cual evaluaremos utilizando cierta métrica.

# Suavizado exponencial simple

En el caso de suavizamiento exponencial simple, se le da más peso a las observaciones recientes y menos peso a las antiguas. ¿ Cómo se hace esto ?

$$\hat{Y}_t = \alpha Y_{t-1} + (1 - \alpha) \hat{Y}_{t-1}$$

Donde  $\hat{Y}_t$  es el valor predicho para el tiempo t, que es un promedio ponderado entre el valor previo predicho  $\hat{Y}_{t-1}$  y el valor actual  $Y_{t-1}$ ,  $\alpha$  se conoce como smooth parameter y toma valores entre 0 y 1.

- Si  $\alpha$  es igual a 1, todas las predicciones *son iguales al último valor observado*. Se le llama un **método ingenuo (naive)**.

# Suavizado exponencial simple

La expresión generalizada de Single Exponential Smoothing:

$$\hat{Y}_t = \alpha Y_{t-1} + \alpha (1 - \alpha) Y_{t-2} + \alpha (1 - \alpha)^2 Y_{t-3} + \dots$$

- Muestra que el peso de las observaciones decrece en forma exponencial a medida que son más antiguas.
- Y  $\alpha$  nos indica *el ratio de caída*. Más cerca de uno, decae más rápido.

# Random Walk

Decimos que un proceso es un random walk (que sigue una trayectoria aleatoria) si:

$$Y_t = Y_{t-1} + \epsilon$$

donde  $\epsilon$  es un ruido blanco conocido como white noise.

- Este ruido conforma la parte de la serie que no se puede predecir a partir de ciertos enunciados. Piensen por ejemplo en las criptomonedas.
- Si el modelo de random walk sigue a la tendencia podemos agregar algo más y representarlo con una constante que normalmente tiene la letra ***d*** la que llamaremos drift o en inglés deriva.

$$Y_t = Y_{t-1} + \epsilon + d$$

# Random Walk

La serie de white noise et debe cumplir con lo siguiente:

- Tiene media igual a cero y varianza constante.
- Es completamente aleatoria.
- Los puntos tienen cero correlación entre ellos.

# Tendencia Lineal

Podemos modelar la tendencia de la serie de diferentes maneras dependiendo de su comportamiento.

- La idea con este modelo es poder predecir utilizando el siguiente modelo lineal:

$$T_t = \beta_0 + \beta_1 \text{ TIEMPO}_t + \epsilon_t$$

donde TIME es una variable dummy de tiempo (secuencia representando el tiempo)

Por lo que ajustamos una regresión lineal.



# Tendencia Cuadrática

La idea con el modelo cuadrático es poder predecir utilizando el siguiente modelo cuadrático que solo es añadir la variable dummy de tiempo al cuadrado y ajustar :

$$T_t = \beta_0 + \beta_1 \text{TIEMPO}_t + \epsilon_t + \beta_2 (\text{TIEMPO}_t)^2$$

# Conclusiones

Una serie de tiempo tiene los componentes:

- Tendencia: el componente “permanente”, el efecto que persiste en el largo plazo.
- Estacionalidad: los movimientos periódicos de la serie.
- Componente aleatorio: son cosas que no presentan un efecto duradero.
- Ciclos: se entiende por cualquier tipo de dinámica no capturada por la tendencia o la estacionalidad.

Tip: Para modelar la tendencia y la estacionalidad podemos usar *dummies de tiempo y estacionales*.

Existen varios *modelos para predecir* los nuevos valores de la serie: En la clase de hoy solo vimos unos pocos pero hay muchos más por lo que recomendamos realizar el curso de series temporales para poder entender más sobre la temática.

**AHORA A PROGRAMAR :D**

# Bibliografía

- [Elements of Forecasting \(2001\) - Libro Completo](#)