

Dados  $x_1, \dots, x_n$  un conjunto de mediciones e  $y_1, \dots, y_n$  conjunto de respuestas. Vamos a llamar a  $x$  **variable regresora/independiente** y a  $y$  la llamaremos **variable de respuesta / variable dependiente**.

En general, vamos a asumir que existe una relación entre  $x$  e  $y$  de la forma:

$$y = f(x, \theta) + \epsilon \leftarrow \text{ruido Gaussiano}$$

En **Predicción** la idea es inferir  $\hat{y} = \hat{f}(x)$ ,  $\hat{f}$  es el estimador de  $f$ ,  $\hat{y}$  es la estimación de  $y$ . La precisión de la medición de  $y$  tiene dos comp. de error: una componente **irreducible** (que es indep. de nuestros datos) y una comp. **reducible**.

Assumiendo que un  $x$  fijo y un  $\hat{f}$  conocido vamos a calcular el **error cuadrático medio** entre  $y$  y su predicción  $\hat{y}$ .

$$\begin{aligned} E(y - \hat{y})^2 &= E(f(x) + \epsilon - \hat{f}(x))^2 \\ &= E(f(x) - \hat{f}(x))^2 + E(\epsilon^2) \leftarrow \text{Var}(\epsilon) \end{aligned}$$



↑ **componente reducible**      ↘ **componente irreducible**

La  $f$  más sencilla es pensar una **relación lineal** →  $f$  es super simple  
 ↳  $f$  es fácil de interpretar  
 ↳ no son muy precisos

Considerando un modelo paramétrico, vamos a pensar a  $f$  con la forma:



$$f(x) = \beta_0 + \sum_{i=1}^n \beta_i x_i$$

$$\text{income} \approx \beta_1 \cdot \text{education} + \beta_2 \cdot \text{seniority}$$

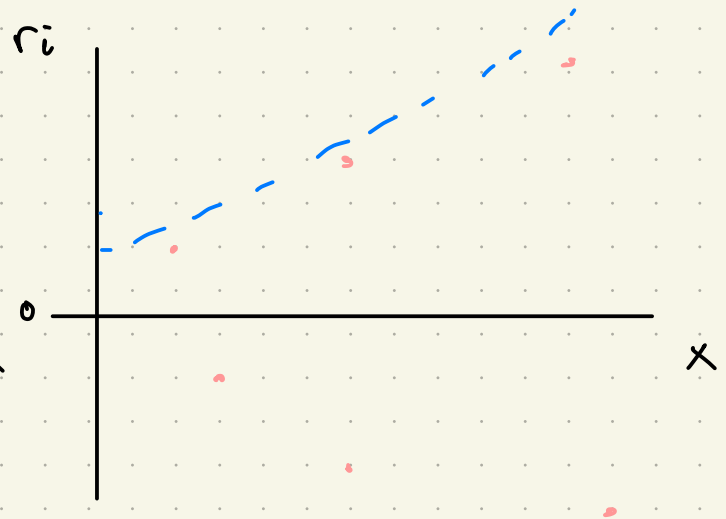


## Condiciones del modelo:

El modelo lineal supone, los regresores sean independientes, los errores iid (independientes e idénticamente distribuidos),  $E(\varepsilon) = 0$ ,  $\text{Var}(\varepsilon) = \sigma^2$ . (homocedasticidad).  $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ .



residuo homocedástico



heterocedástico

Con estas cond. estoy limitando como encontrar  $\hat{f}$  como el mejor

Tenemos 3 met  $\rightarrow$  MSE (mean square error)  
 $\rightarrow$  ML (Maximum Likelihood)  
 $\rightarrow$  MAP (maximum a posteriori)

**MSE:** partiendo de un dataset  $D = \{(x_i, y_i) \mid i \in [1, \dots, n], x_i \in \mathbb{R}^{m \times 1}\}$

$$\mathcal{E}(\beta) = \sum_{n=1}^N (y_n - \hat{f}(x_n))^2 = \sum_n (y_n - \beta_0 - \sum_i x_i \cdot \beta_i)^2$$

al vector  $x_i$  le agrego 1 para representar el termino indep. ( $\beta_0$ ),  
entonces  $x_i = [1, x_1, \dots, x_n]$ , con esto, puedo escribir:

$$\begin{aligned}\mathcal{E}(\beta) &= \sum_n (y_n - \sum_j \beta_j \cdot x_{ij})^2 \\ &= (y - X\beta)^T (y - X\beta)\end{aligned}$$

Ahora tenemos  $\mathcal{E}(\beta)$  y quiero optimizarlo  $\Rightarrow$  tengo que minimizarlo:

$$\begin{aligned}\partial_\beta \mathcal{E} &= 0 = \partial_\beta [(y - X\beta)^T (y - X\beta)] \\ &= -2X^T (y - X\beta) \\ &= X^T (y - X\beta) \\ &= X^T y - X^T X \beta \Rightarrow \boxed{\hat{\beta} = (X^T X)^{-1} X^T y}\end{aligned}$$


$$\hat{y} = H y \rightarrow H = X (X^T X)^{-1} X^T \quad \left( \begin{array}{l} \text{pseudoinversa} \\ \text{Moore Penrose} \end{array} \right) \quad \underbrace{\hspace{1cm}}_H$$

2. Método ML (Maximum Likelihood - Máxima verosimilitud):

$$\hat{\beta}_{ML}, \text{ partimos de } y_i = \hat{f}(x_i) + \varepsilon \quad \varepsilon \sim N(0, \sigma^2)$$

$$P(Y | X, \beta) = P(y_1, y_2, \dots, y_n | x_1, \dots, x_n, \beta)$$

$$\begin{array}{l} \text{x sup.} \\ \text{iid} \end{array} \quad \downarrow \quad = \prod_{n=1}^N P(y_n | x_n, \beta) \sim \mathcal{N}(y_n / x_n^T \theta, \sigma^2)$$



buscamos el  $\hat{\beta}_{ML} = \arg \max (P(Y | X, \beta))$ :

$$\mathcal{L}(\beta) = \arg \max \left( \underbrace{P(y|x, \beta)}_{\pi \dots} \right)$$

$$\log(\mathcal{L}(\beta)) = \arg \max (\log(P(y|x, \beta)))$$

$$\mathcal{L}(\beta) = - \arg \min (\underbrace{\log(P(y|x, \beta))}_{\textcircled{2}})$$

$$\textcircled{1} \log(P(y_n | x_n, \beta)) = \frac{1}{2\sigma^2} (y_n - x_n^t \beta)^2 + c$$

$$\mathcal{L}(\beta) = \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - x_n^t \beta)^2 = \frac{1}{2\sigma^2} (y - X\beta)^t (y - X\beta)$$

$$= \frac{1}{2\sigma^2} \|y - X\beta\|^2$$

Vamos a optimizar  $\mathcal{L}(\beta)$ :

$$\partial_{\beta} \mathcal{L}(\beta) = 0 = \partial_{\beta} \left( \frac{1}{2\sigma^2} (y - X\beta)^t (y - X\beta) \right)$$

$$= \partial_{\beta} (y^t y - 2y^t X \beta_{ML} + \beta_{ML}^t X^t y \beta_{ML})$$

$$= 0 - 2y^t X + 2\beta_{ML}^t X^t X$$

$$= -y^t X + \beta_{ML}^t X^t X$$

$$\hookrightarrow \beta_{ML}^t X^t X = y^t X$$

$$\beta_{ML}^t = y^t X (X^t X)^{-1}$$

$$\boxed{\beta_{ML} = (X^t X)^{-1} X^t y}$$