

Introducción a IA.

En el caso general: $y = f(\bar{x}, \bar{\beta})$ $\bar{x} = (x_1, x_2, \dots, x_n)$ $\hat{\beta} = (x^T x)^{-1} x^T y$
features

Para el análisis de hoy consideramos el caso lineal simple $\Rightarrow \bar{x} \in \mathbb{R}$,
con esto, tenemos $y = \beta_0 + \beta_1 x$.

Ejemplos de modelos lineales: $\rightarrow y = \beta_0 + \beta_1 x$

$$\hookrightarrow y = \beta_0 x^{\beta_2} \rightarrow \ln(y) = \ln(\beta_0) + \beta_2 \ln(x)$$

$\hookrightarrow \exp(\cdot)$

\hookrightarrow modelo generalizado

$y = \beta_0 + \beta_1 x + \beta_2 x^2 \rightarrow$ modelo lineal con los β
no lineal con x .
(linealizables*)

• Analizando la regresión simple.


recordemos que:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$r_i = y_i - \hat{y}_i \leftarrow i\text{-ésimo residuo}$$

suma de cuadrados
de
residuos

$$RSS = \sum_i r_i^2$$



$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} \sum_i \underbrace{(y_i - \beta_0 - \beta_1 x_i)^2}_{\textcircled{1}}$$

$$\begin{cases} \partial_{\beta_0} \sum_i \textcircled{1}^2 = -2 \sum_i (y_i - \beta_0 - \beta_1 x_i) & \rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \partial_{\beta_1} \sum_i \textcircled{1}^2 = -2 \sum_i (y_i - \beta_0 - \beta_1 x_i) x_i & \rightarrow \hat{\beta}_1 = \frac{\frac{1}{N} \sum_i (x_i - \bar{x})(y_i - \bar{y})}{\underbrace{\frac{1}{N} \sum_i (x_i - \bar{x})^2}_{\text{var}(x)}} \end{cases}$$

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{\text{cov}(x, y)}{\text{var}(x, y)} = \underbrace{\hat{\rho}_{xy}}_{\text{coef. de correlación de Pearson}} \frac{s_y}{s_x} \end{cases} \rightarrow \text{Estimadores de la varianza}$$

\hookrightarrow coef. de correlación de Pearson

$$\text{cov}(x, y) = E(x, y)^2, \quad \text{cov}(x, x) = \text{var}(x)$$

Ahora analizamos los errores:

$$y_i = \hat{y}_i + r_i$$

$$y_i - \bar{y} = \hat{y}_i - \bar{y} + r_i$$

$$\sum_{i=0}^n (y_i - \bar{y})^2 = \sum_{i=0}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=0}^n r_i^2$$

$$TSS = ESS + RSS$$

↓
taza de
variabilidad
total

↳ suma de
explicados al
modelo

↳ suma de cuadrado
de residuos

Con este approach puedo construir test estadísticos para validar el modelo. (lo vemos más adelante).

¿Cómo se que mi modelo es bueno?

→ Error residual (ASE)

↳ Estadístico R^2

↳ n F

$$+ RSE = \sqrt{\frac{RSS}{n-2}} = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n-2}} \rightarrow \text{me interesa que sea bajo.}$$

+ $R^2 \rightarrow$ mide la bondad del ajuste.

↳ equivalente al coef. de correlación al cuadrado entre x e y .

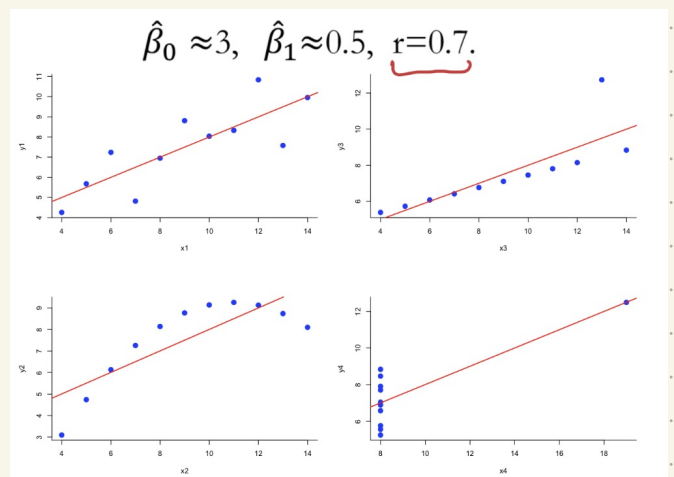
$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} = \hat{\beta}_{xy}^2 \quad (\text{esto en regresión simple})$$

+ R^2 no depende de las unidades de y , solo de las proporciones.

+ $R^2 \in [0, 1]$

+ $R^2 \approx 1$ es un "buen" ajuste.

(NO SIEMPRE) →



Estadístico F:

Armando la tabla ANOVA del ajuste:

| Fuentes de Variación | SS | gl | val. medios | |
|----------------------|----------------------------------|-----|------------------------------------|---|
| Explicada (ESS) | $\sum_i (\hat{y}_i - \bar{y})^2$ | 1 | $\sum_i (\hat{y}_i - \bar{y})^2$ | F |
| Residual (RSS) | $\sum_i r_i^2$ | n-2 | $s_R^2 = \frac{\sum_i r_i^2}{n-2}$ | |
| Varia. total (TSS) | $\sum_i (y_i - \bar{y})^2$ | n-1 | | |

construimos $F = \frac{ESS}{s_R^2} \rightarrow$ Si F es muy grande (la var. explicada es muy grande respecto a la no explicada) vamos a **rechazar** H_0 con H_0 siendo:

$$TH: \underbrace{H_0: \beta_1 = 0}_{\text{Hipótesis nula}} \wedge \underbrace{H_1: \beta_1 \neq 0}_{\text{hip. Alternativa}} \Rightarrow P(F > f_{g1, \alpha})$$

$f_{1, n-2, 1-\alpha}$

Como interpretamos las hipótesis:

+ **Hipótesis nula (H_0):** Con esto vamos a suponer que el modelo de regresión lineal aún **no explica mejor la varianza que un modelo constante.**

+ **Hipótesis Alternativa (H_1):** El modelo obtenido explica mejor (es **estadísticamente significativo**) la **varianza** en la respuesta que un modelo constante.

- Como calculamos el F-test?

1. Armamos la tabla ANOVA.

2. Obtenemos el estadístico $F_3 = \frac{ESS}{s_R^2}$

3. Calculamos el f_{crit} (p-valor) a partir de los parámetros obtenidos:

$$f \sim F_{g1/2, g2/2}$$

4. para un dado α (típicamente $\alpha = 0.05$):

buscamos f_{crit} tal que:

$$P(F > f_{crit}) = \alpha$$

5. Si $F_3 > f_{crit} \Rightarrow$ **Rechazo H_0 .**

