

Introducción a la Inteligencia Artificial  
Facultad de Ingeniería  
Universidad de Buenos Aires

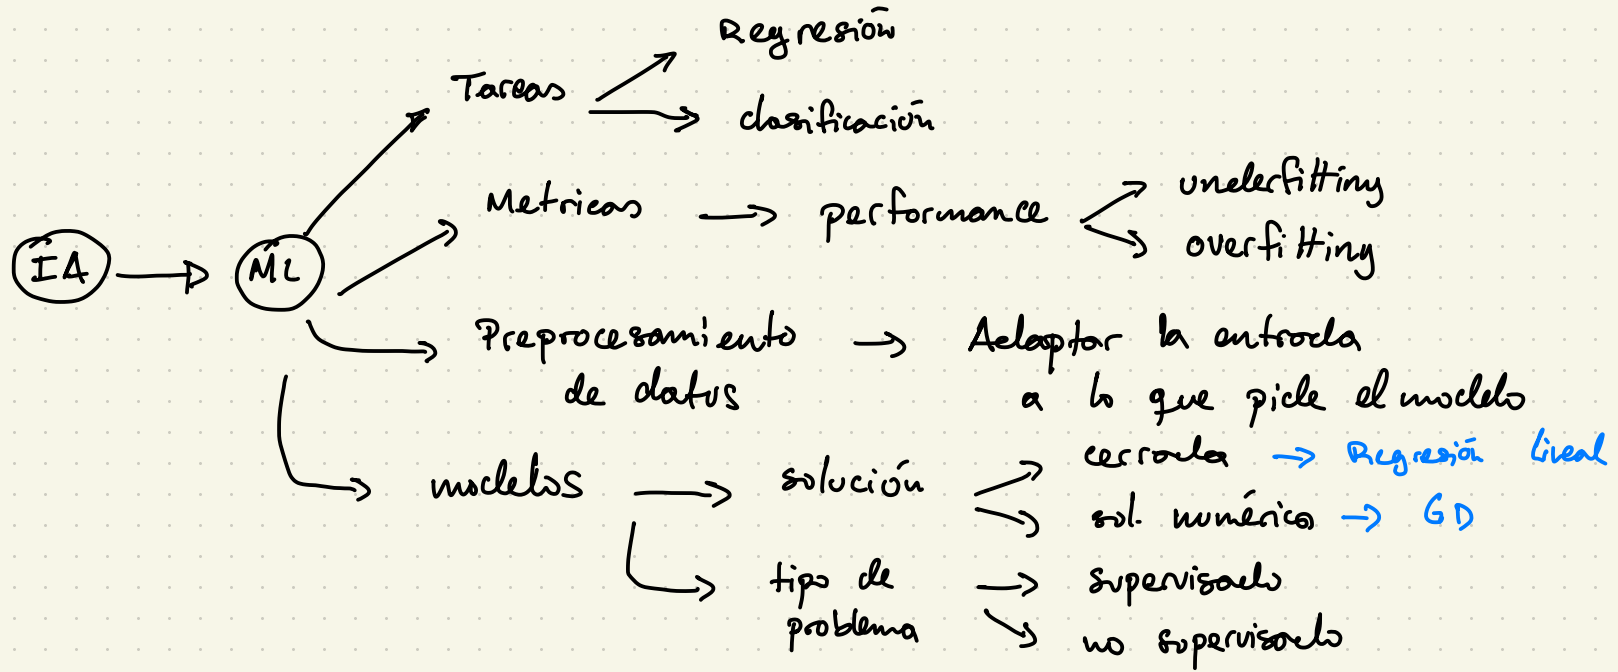


## Clase 6

1. Clasificación Binaria
  - a. Motivación
  - b. Regresión Logística - Ejercicio de Aplicación
  - c. Regresión Logística - Teoría
2. Clasificación Multiclase
  - a. Motivación
  - b. Softmax
  - c. Ejercicio de Aplicación
3. Ejercicio integrador



# Resumen



## Clasificación Binaria - Motivación

- Credit Card Fraudulent Transaction Detection
- Medical Diagnosis
- Spam Detection
- Sentiment Analysis
- Binary Image Classification

**Clasificación:** queremos mapear  $X \in \mathbb{R}^{m \times n}$  en  $K$  clases


① Clases separables: cada input tiene un único output.  
En este régimen, el espacio se divide en regiones de decisión.

modelos  $\rightarrow$  lineales  $\rightarrow$  Reg. logística, SVM, LDA

$\hookrightarrow$  no lineales  $\rightarrow$  KNN

$\mathcal{D} = \{(\bar{x}_1, y_1), \dots, (\bar{x}_n, y_n)\}$ ,  $y_i = (0, \dots, 1, \dots, 0)$  **vector one-hot**

$$y_{ij} = \begin{cases} 1 & \text{si } \bar{x}_i \text{ pertenece a } j \\ 0 & \text{over.} \end{cases}$$



# Métricas

Matriz de confusión:

		Pred	
		T	F
GL	T	TP	FN
	F	FP	TN

GL: gold label, Ground Truth, valor verdadero

TP: # muestras positivas que predice positivas.

TN: # " negativos " " negativos.

FN: # " " " positivos

FP: # " positivas " " negativos

$$\text{Accuracy} = \frac{TP + TN}{\#P + \#N} \in [0, 1]$$

$$\text{specificity (TN rate)} = \frac{TN}{TN + FP}$$

$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{Recall (TP rate)} = \frac{TP}{P}$$

$$\begin{aligned} F_1 &= 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \\ &= \frac{TP}{TP + \frac{1}{2}(FP + FN)} \end{aligned}$$

$$F_\beta = (1 + \beta^2) \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}$$

## Formas de clasificar:

definir un proc de scoring  $\rightarrow$  resolver la decisión

+ complejidad en el modelo  $\Rightarrow$  + complejidad en el computo  $\stackrel{?}{\Rightarrow}$  mejor modelo.

① Modelos Generativos: modelar la distrib. de inputs y de outputs  $\Rightarrow$  Permite generar y samplear datos sintéticos (GAN's).


② Modelos discriminantes: planteo una distrib.  $P(C_k|X)$  usando inferencia Bayesiana obtengo mi modelo. Una vez obtenido usamos el modelo.

③ Modelos func. ó discriminantes: buscamos  $f(X) : \mathbb{R}^{n \times m} \rightarrow [C_1, C_2, \dots, C_K]$

## Regresión Logística




Usamos la función logística (Sigmoides/sigmoide)  $\sigma(a) = (1 + e^{-a})^{-1} \rightarrow$  pertenece a la familia de fn. squashing:

$$f: x, a \rightarrow y \\ \mathbb{R} \rightarrow [0, 1]$$



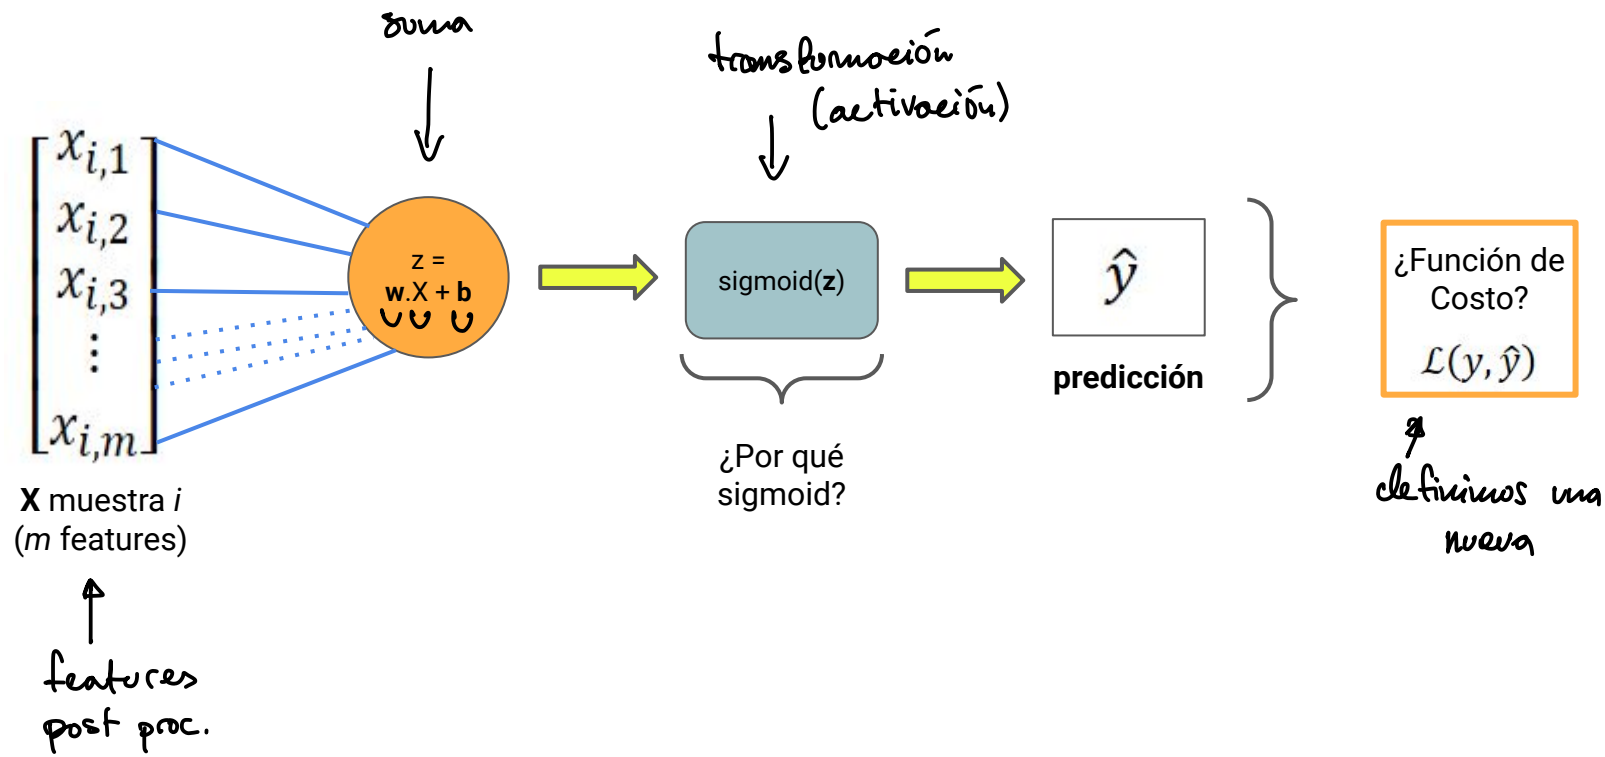
## Clasificación Binaria - Motivación

$(x,y) \rightarrow (C, P(C))$



$T_h$  por default es 0,5

## Regresión Logística





queremos mapear  $\sigma(a)$ , partimos de  $z = w^t x$

$$\sigma(z) = \sigma(w^t x)$$

$$\partial_a \sigma(a) = \sigma(a) (1 - \sigma(a)) \quad (\text{propiedad})$$

$$\partial_w \sigma(z) = \sigma(w^t x) (1 - \sigma(w^t x)) x$$

$$\text{Verosimilitud: } P(y|x) = \prod_{n=1}^N \hat{y}_n^{y_n} (1 - \hat{y}_n)^{1 - y_n}$$

$N = \#$  muestras

$\hat{y} = \text{pred}$

$y = \text{GL}$

$$\hat{y} = P(c|x)$$

$$\max_w \sum_{i=1}^N \ln (P_w(y_i = g_i | \bar{x}_i = x_i))$$

$$\max_w \sum_{i=1}^N \ln (\sigma(w^t x)^{y_i} \cdot (1 - \sigma(w^t x))^{1 - y_i})$$

$$\max_w \sum_{i=1}^N y_i \ln \sigma(w^t x) + (1 - y_i) \cdot \ln (1 - \sigma(w^t x))$$



$\rightarrow x(-1)$

$$\min_w \sum_{i=1}^N -y_i \text{ a} - (1 - y_i) \text{ b}$$

a ① podemos aproximar usando:




$$J(w) = \frac{1}{n} \sum_{i=1}^N [-y_i \text{ a} - (1 - y_i) \text{ b}]$$

binary cross entropy








$$\bar{\nabla}_w J(w) = 0 \rightarrow \begin{array}{l} \text{GD} \\ \searrow \\ \text{SGD} \\ \swarrow \\ \text{GDB} \end{array}$$

## Regresión Logística




## Regresión Logística



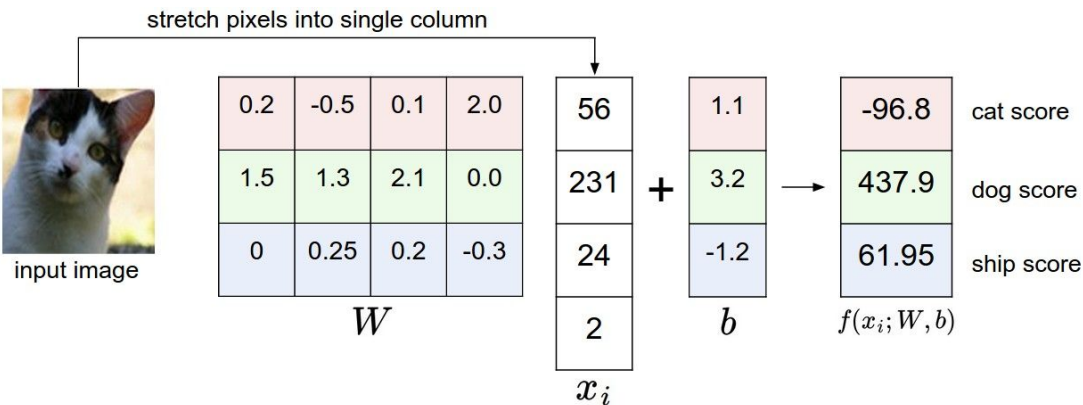
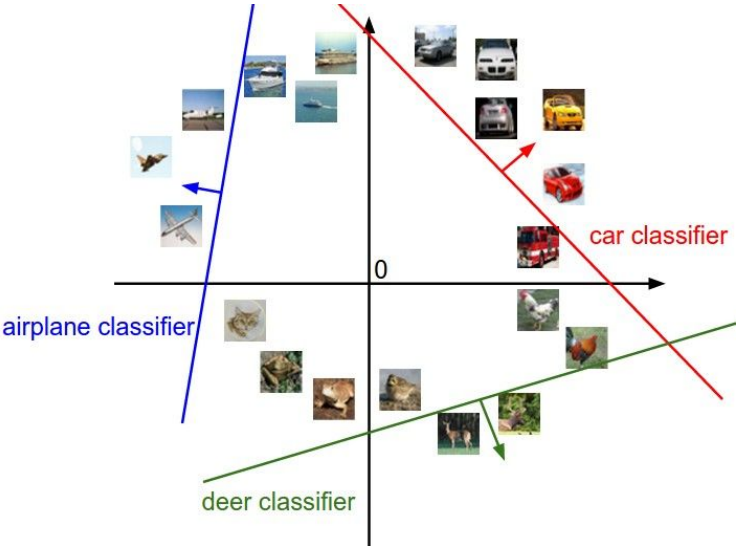
## Regresión Logística

$$H_p(q) = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$

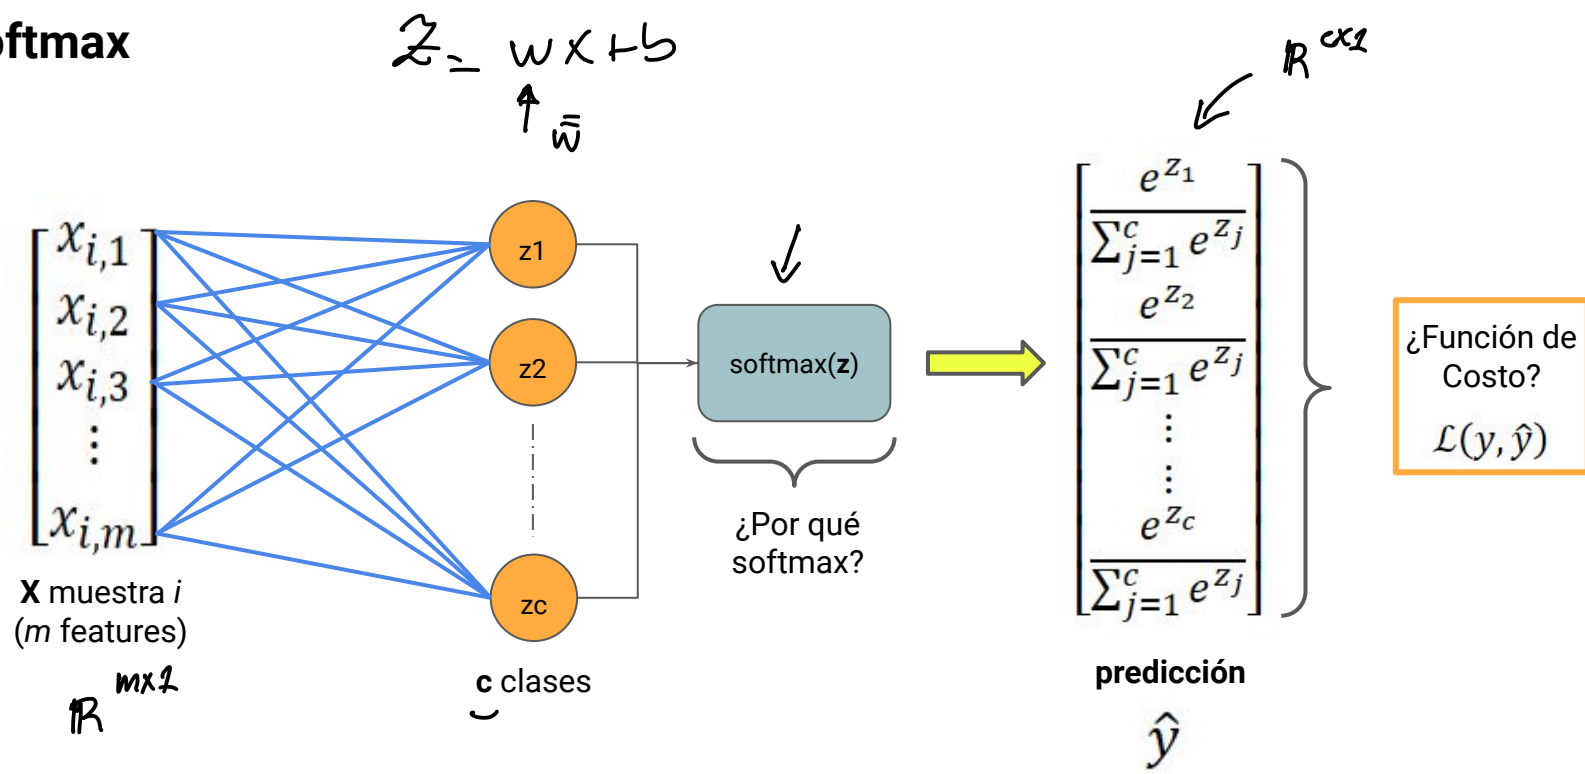


## **(1) REGRESIÓN LOGÍSTICA - EJERCICIO DE APLICACIÓN**

## Clasificación Multiclase - Motivación



## Softmax





## Softmax

probabilidad de ser clase  $y_i$   
dado los  $\pi_i$  y los coef  $w$ .

$$P(y_i | x_i; W) = \frac{e^{f_{y_i}}}{\sum_j e^{f_j}}$$

$$\frac{e^{f_{y_i}}}{\sum_j e^{f_j}} = \frac{C e^{f_{y_i}}}{C \sum_j e^{f_j}} = \frac{e^{f_{y_i} + \log C}}{\sum_j e^{f_j + \log C}}$$

$q(x)$

$$H(p, q) = - \sum_x p(x) \log q(x)$$

1

[Softmax Forma Gráfica](#)

2

[Softmax Visualización 3D](#)

## Softmax

### Derivación Softmax

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

$$\frac{\partial p_i}{\partial z_k} = \frac{\partial \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}}{\partial z_k}$$

$$\frac{\partial p_i}{\partial z_k} = p_i(\delta_{ik} - p_k) \quad \delta_{ik} = \begin{cases} 1, i = k \\ 0, i \neq k \end{cases}$$

Usar gradiente descendente para actualizar W !!!

### Derivación Cross-Entropy

$$\begin{aligned} L &= - \sum_i y_i \log(p_i) \\ \frac{\partial L}{\partial z_i} &= - \sum_j y_j \frac{\partial \log(p_j)}{\partial z_i} \\ &= - \sum_j y_j \frac{\partial \log(p_j)}{\partial p_j} \times \frac{\partial p_j}{\partial z_i} \\ &= - \sum_j y_j \frac{1}{p_j} \times \frac{\partial p_j}{\partial z_i} \end{aligned}$$

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= -y_i(1 - p_i) - \sum_{j \neq i} y_j \frac{1}{p_j} (-p_j \cdot p_i) \\ &= -y_i(1 - p_i) + \sum_{j \neq i} y_j \cdot p_i \\ &= p_i \left( y_i + \sum_{j \neq i} y_j \right) - y_i \end{aligned}$$

$$\frac{\partial L}{\partial z_i} = p_i - y_i$$

$$\frac{\partial z_i}{\partial W} = x_i$$

$$\frac{\partial L}{\partial W} = \sum_{i=1}^N (p_i - y_i) x_i$$



## **(1) SOFTMAX - EJERCICIO DE APLICACIÓN**

## Bibliografía

- The Elements of Statistical Learning | Trevor Hastie | Springer
- An Introduction to Statistical Learning | Gareth James | Springer
- Deep Learning | Ian Goodfellow | <https://www.deeplearningbook.org/>
- Mathematics for Machine Learning | Deisenroth, Faisal, Ong
- Artificial Intelligence, A Modern Approach | Stuart J. Russell, Peter Norvig
- Understanding binary cross-entropy: a visual explanation | Daniel Godoy
- Visual Information Theory | [Link](#)
- <https://cs231n.github.io/>
- Classification and Loss Evaluation-Softmax and Cross Entropy Loss | Paras Dahal

